

Arquitectura de la Aplicación

La arquitectura fue diseñada para desplegarse en Google Cloud Platform (GCP). Está compuesta por una VPC que contiene dos subredes con propósitos específicos. La primera subred utiliza el segmento 10.109.1.16/28 y está destinada a los componentes de backend y worker, mientras que la segunda subred (10.109.1.0/28) se especializa en el frontend. Esta división permite una estructura clara y un aislamiento adecuado entre los diferentes componentes del sistema.

En la primera subred se implementaron dos máquinas virtuales con funciones complementarias. La instancia-backend se encarga de ejecutar el microservicio principal del backend, actuando como el núcleo de procesamiento. Por otro lado, la worker-instance gestiona tareas especializadas como la lectura, transformación e inserción de vectores en la base de datos, además de interactuar con el modelo Gemini para el procesamiento avanzado de consultas. Esta subred también alberga dos bases de datos Cloud SQL: una relacional para la gestión de usuarios y otra vectorial para almacenar los embeddings generados a partir de los documentos. Adicionalmente, incorpora un servicio Filestore configurado como NFS y montado en la instancia-backend, proporcionando almacenamiento persistente para los documentos de los usuarios.

La segunda subred está dedicada exclusivamente al frontend, conteniendo la instancia-front que ejecuta el microservicio de interfaz de usuario. Esta separación física garantiza un mejor control de acceso y seguridad, al mismo tiempo que optimiza el rendimiento al especializar cada subred en un conjunto específico de funciones.

La arquitectura se complementa con servicios gestionados de GCP que potencian su funcionalidad. El Artifact Registry actúa como repositorio centralizado para las imágenes Docker utilizadas en los despliegues. El servicio Gemini se integra para proporcionar capacidades avanzadas de procesamiento de lenguaje natural. Finalmente, se implementaron reglas de firewall específicas para regular el tráfico entre las subredes, asegurando comunicaciones seguras y controladas. La Figura 1 presenta de manera detallada esta arquitectura completa y sus interconexiones.




Figura 1. Arquitectura de la solución.

Conclusiones de pruebas de carga

Durante las pruebas de carga, se identificó que el microservicio del backend experimentó una degradación al alcanzar un umbral de 70 usuarios interactuando con una ruta crítica del aplicativo (desde el login hasta la carga del documento), lo que generó un encolamiento de peticiones. El escenario evaluado simuló 150 usuarios en 120 segundos, evidenciando que las limitaciones de recursos de la única máquina virtual asignada al microservicio fueron un factor determinante en el colapso. Por otro lado, servicios administrados como Cloud SQL y Filestore —al ser soluciones PaaS con escalado automático gestionado por Google Cloud— no representaron puntos únicos de fallo, ya que garantizaron disponibilidad y adaptabilidad ante el aumento de demanda sin intervención manual.

Durante el análisis de los componentes desplegados, se observó que la máquina virtual que aloja los workers de la capa de proceso presentaba un alto consumo de recursos, alcanzando aproximadamente el 70% de su capacidad antes de que la aplicación colapsara. Este comportamiento indicó que, bajo la misma rampa de tiempo, un incremento en el número de usuarios comprometería aún más los tiempos de respuesta, acelerando la saturación del servicio.

La evidencia sugiere que los recursos asignados resultan insuficientes para manejar picos de demanda, lo que exige una revisión de la capacidad de procesamiento o estrategias de escalado para garantizar estabilidad.

Consideraciones adicionales

Para garantizar el escalamiento eficiente de la aplicación web y atender un mayor volumen de usuarios, es fundamental considerar aspectos clave de la infraestructura. Una de las prioridades es adoptar el servicio de contenedores CloudRun para gestionar y ejecutar los microservicios de la plataforma. Esta solución ofrece escalamiento horizontal automático, lo que permite adaptarse rápidamente a picos de demanda sin intervención manual, asegurando un rendimiento óptimo incluso con una alta concurrencia de usuarios interactuando simultáneamente con el sistema.

Además, resulta estratégico implementar un balanceador de carga externo que distribuya el tráfico entrante entre los contenedores del frontend alojados en CloudRun. Esta herramienta no solo optimiza la distribución de solicitudes para evitar sobrecargas en instancias específicas, sino que también incorpora una capa adicional de seguridad, protegiendo la aplicación contra posibles amenazas externas.

Por otro lado, se recomienda desplegar un balanceador interno dedicado a gestionar la comunicación entre los microservicios de la capa de procesamiento (worker). Este componente cumplirá un rol crítico en el enrutamiento de solicitudes, tanto para la carga y procesamiento de documentos como para las consultas generadas por los usuarios en el prompt. Al distribuir eficazmente estas tareas, se asegura un flujo de trabajo estable y escalable, mejorando la capacidad de respuesta del sistema en escenarios de alta demanda.